

# Smart Agriculture

Drd. Mureșan Horea

# Cuprins

1. Motivație
2. Obiective
3. Metodologie
  - a. Familii de detectori
  - b. Structura generală
4. Crearea unui set de date
  - a. Factori ce afectează calitatea unui set de date
5. Seturi de date existente

## Raționamente pentru sisteme inteligente în agricultură

- Forța de muncă disponibilă este în scădere raportată la efortul aferent procesului de cultivare, îngrijire și recoltă
- Interesul pentru specializări în domenii ale agriculturii este în scădere

# Raționamente pentru sisteme inteligente în agricultură

- Costul materialelor pentru tratamente preventive și pentru fertilizare
- Costul închirierii sau a întreținerii spațiilor de depozitare pentru produse

# Raționamente pentru sisteme inteligente în agricultură

- Monitorizarea dezvoltării și sănătății plantelor
  - Proces continuu, consumator de timp
  - Necesită inspecție sau analize conduse de experți
  - Potențial susceptibilă la eroare umană

# Obiective

- Detectarea fructelor de pe plante (pomi, arbuști, vițe, etc)
  - Estimarea recoltei
    - estimarea spațiului necesar pentru depozitare
    - estimarea resurselor necesare pentru recoltă
- Identificarea frunzelor afectate de boli
  - Monitorizarea stării de sănătate a plantelor
    - mărirea vitezei de reacție la apariția bolilor
    - aplicarea de tratamente specifice

# Metodologie

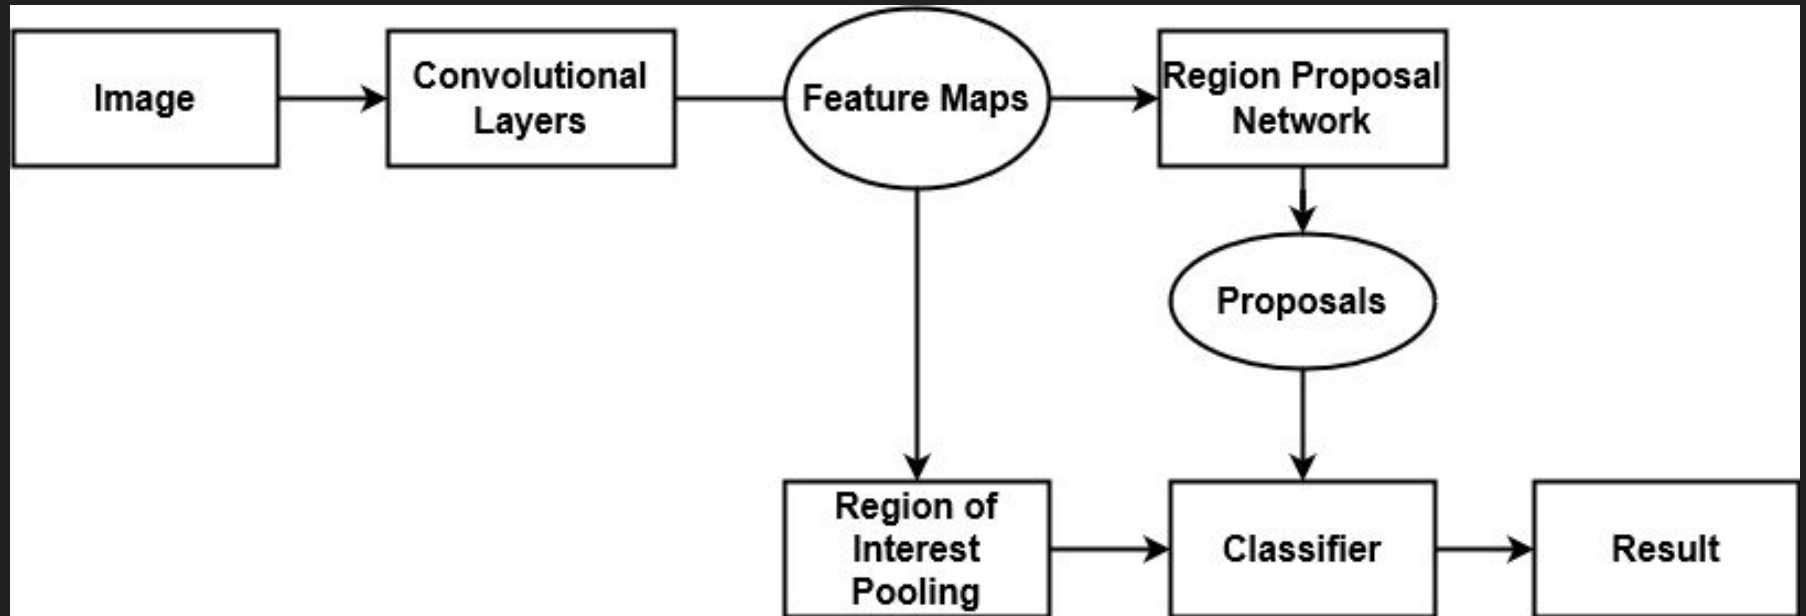
- Localizare obiecte
  - Input: Imagine cu unul sau mai multe obiecte
  - Output: Listă de tuple-uri ce reprezintă regiuni din imagine care conțin obiecte (de obicei reprezentate prin coordonatele unui punct + înălțime și lățime)
- Clasificare obiecte
  - Input: Imagine cu un singur obiect
  - Output: O etichetă sau clasă ce reprezintă obiectul din imagine
- Detecție obiecte
  - Input: Imagine cu unul sau mai multe obiecte
  - Output: Listă de tuple-uri ce reprezintă regiuni din imagine care conțin obiecte împreună cu clasa asociată fiecărui obiect

# Clase de detectori

- R-CNN (Region-based convolutional neural network)
  - Fast R-CNN
  - Faster R-CNN
- SSD (Single Shot MultiBox Detector)
- YOLO (You Only Look Once)



# Structure Faster R-CNN



# Crearea seturilor de date



- Culegerea datelor
  - Asigurarea unui grad suficient de varianță
  - Echilibrarea numărului de imagini per clasă
- Adnotări
  - asocierea unei clase fiecărei imagini (clasificare)
  - asocierea unor bounding boxes + clasă (detectie)
- Augmentare date (opțional)
  - Decupare, rotație, modificare nivel zoom
  - Modificarea nivelurilor de luminozitate, contrast, saturație

# Factori



- Variația condițiilor de iluminare
  - Condiții meteorologice
  - Densitatea frunzelor și locația fructelor
- Variația nivelului de ocluzie
  - Densitatea frunzelor și locația fructelor
- Variația introdusă de poziționarea obiectivului
  - Unghiul la care se fac poze
  - Distanța de la care se fac poze











# Instrumente de lucru

- Implementare rețele neuronale:
  - Tensorflow
  - Keras
  - Pytorch
  - Caffe
- Prelucrare imagini:
  - OpenCV
  - Pillow
- Utile:
  - csv - fișiere cu date separate de virgulă
  - pickle - serializare date
  - pandas - reprezentare date tabelare

# Seturi de date - Fructe

- Clasificare

- <https://github.com/Horea94/Fruit-Images-Dataset>
- <https://www.kaggle.com/datasets/moltean/fruits>

- Detecție

- <https://www.kaggle.com/datasets/mbkinaci/fruit-images-for-object-detection>

- Imagini fără adnotări pentru detecție

- <https://www.kaggle.com/datasets/aelchimminut/fruits262>
- <https://www.kaggle.com/datasets/kritikseth/fruit-and-vegetable-image-recognition>



# Seturi de date - Frunze

Clasificare boli pe baza imaginilor cu frunze:

- <https://www.kaggle.com/c/cassava-leaf-disease-classification/>
- <https://www.kaggle.com/datasets/kaustubhb999/tomatoleaf>
- <https://www.kaggle.com/datasets/smaranjitghose/corn-or-maize-leaf-disease-dataset>